

Seurat_tutorial

2026-03-29

Deelvraag: Hoe kan Seurat worden gebruikt om single-cell RNA-seq data te verwerken, analyseren en interpreteren om verschillende celpopulaties te identificeren?

Methode

Voor deze analyse is er gebruikgemaakt van het Seurat-pakket in R, een veelgebruikt hulpmiddel voor de analyse van single-cell RNA-seq data. De workflow is gebaseerd op de officiële Seurat-tutorial, deze is beschikbaar via de volgende site: https://satijalab.org/seurat/articles/pbmc3k_tutorial. Als voorbeeld werd een publieke dataset gebruikt bestaande uit 2.700 perifere bloed mononucleaire cellen (PBMC's), gegenereerd met het 10X Genomics-platform. De sequencing is uitgevoerd op een Illumina NextSeq 500 en de ruwe data is beschikbaar via de volgende site: https://cf.10xgenomics.com/samples/cell/pbmc3k/pbmc3k_filtered_gene_bc_matrices.tar.gz.

De analyse bestaat uit een vaste workflow:

- kwaliteitscontrole enfiltering van cellen
- normalisatie en selectie van informatieve genen
- dimensiereductie en clustering van cellen
- identificatie van cluster-specifieke genexpressie
- biologische interpretatie en annotatie van clusters

Deze stappen zijn bedoeld om technische ruis te verminderen en biologische variatie tussen cellen inzichtelijk te maken.

Resultaten:

Kwaliteitscontrole en filtering

In Figure 1 worden de features, counts en percentage mitochondria weergegeven. In figure 2 wordt de data van figure 1 tegen elkaar uitgezet in een scatterplot. De kwaliteitscontrole laat zien dat er een licht negatieve correlatie is van -0.13 tussen mitochondriaal RNA en het totale RNA binnen de PBMC's. Ook is er een sterke positieve correlatie van 0.95 tussen het aantal unieke genen en het totale RNA binnen de PBMC's, dit geeft aan dat cellen met meer RNA ook meer unieke genen bevat. Van de features blijven tussen de 200 en 2500 over. Van de mitochondria blijft onder de 5% over, daarboven is de cel waarschijnlijk van slechte kwaliteit of is deze stervende.




Figure 1: Vioolplots: Er zijn drie vioolplots naast elkaar weergegeven. In alle drie de vioolplots wordt op de x-as de dataset met pbmc's weergegeven. Elke stip representeert een individuele cel. Links wordt op de y-as het aantal unieke features weergegeven. In het midden wordt op de y-as het aantal RNA binnen de cel weergegeven. Rechts wordt op de y-as het percentage mitochondriale genen weergegeven.




Figure 2: FeatureScatterplots: Er zijn twee scatterplots naast elkaar weergegeven, bij beide scatterplots staat op de x-as het aantal RNA binnen de cel. Elke stip representeert een individuele cel. Links is op de y-as het percentage mitochondriale genen weergegeven, waarbij alleen cellen meegenomen zijn die een percentage lager dan 5% mitochondriale genen hebben. Rechts is op de y-as het aantal unieke features per cel weergegeven, waarbij alleen de cellen meegenomen zijn die tussen de 200 en 2500 unieke features hebben.

Normaliseren van de gegevens

De data wordt genormaliseerd door de totale expressie van elke cel om te zetten naar 10.000 en vervolgens een log-transformatie te nemen (het getal weer kleiner maken). Hierdoor kunnen de getallen per cel met elkaar vergeleken worden.

Kenmerkselectie

In Figure 3 zijn de 2000 cellen met de meest variërende kenmerken zijn rood gekleurd en de 10 meest variërende genen worden aangegeven met hun naam.




Figure 3: VariableFeaturePlot: Op de x-as wordt de gemiddelde expressie weergegeven. Op de y-as wordt de standaard variantie weergegeven. De 2000 cellen met de meest variërende kenmerken zijn rood gekleurd en de 10 cellen met de meest variërende genen zijn aangegeven met hun naam.

De gegevens schalen

De gemiddelde expressie over de cellen wordt op 0 gesteld, ook wordt de variantie over de cellen op 1 gesteld.

Lineaire dimensionale reductie uitvoeren

Met behulp van principal component analyses (PCA) worden er van de oude variabelen, nieuwe variabelen gemaakt door lineaire combinaties te maken. Hieruit ontstaan enkele hoofdcomponenten (PC's). PC1 dekt het grootste deel van de variatie binnen de data. PC2 dekt daarna het grootste deel, enzovoort.




Figure 4: VizDimLoadings. De topgenen worden weergegeven die geassocieerd worden met PC1 of PC2.




Figure 5: DimPlot, Op de x-as wordt PC1 geplott en op de y-as wordt PC2 geplott. Elke stip representeert een individuele cel.




Figure 6: DimHeatmap, PC1 wordt weergegeven met als de verschillende genen in de rijen, en verschillende cellen in de kolommen. Paars is een lage PCA-score, geel is een hoge PCA-score. Clusters worden hiermee gevisualiseerd

Dimensionaliteit

Om ruis te voorkomen in verdere analyse wordt er gekeken hoeveel PC's meegenomen moeten worden. Hiervoor kan er gebruik gemaakt worden van een elbowplot. In deze plot worden de PC's op de x-as geplaatst en de standaard deviatie op de y-as. Er ontstaat een soort van arm, waarbij de elleboog het keerpunt is. De PC's voor de elleboog worden meegenomen en de PC's na de elleboog worden niet meegenomen. Het verschil tussen de PC's na de elleboog is niet relevant genoeg om mee te nemen. In Figure 7 is de elleboog zichtbaar tussen 9 en 10.




Figure 7: ElbowPlot: Op de x-as staan de PC's en op de y-as staan de standaard deviatie.

Clusteren

Nadat de juiste PC's zijn gekozen (1-10), verdeelt Seurat de cellen in groepen (clusters). Het programma kijkt hiervoor welke cellen het meest op elkaar lijken en verbindt die in een netwerk. Vervolgens zoekt het naar dicht bij elkaar liggende groepjes cellen binnen dat netwerk. Met de resolutie-instelling kun je bepalen of je grotere, bredere groepen of juist kleinere, gedetailleerdere groepen krijgt. In dit geval is er gekozen voor een resolutie van 0.5.

Niet-lineaire dimensionale reductie uitvoeren (UMAP/tSNE)

Seurat kan technieken zoals UMAP en tSNE gebruiken om de data overzichtelijk weer te geven in twee dimensies. Deze methoden plaatsen cellen die op elkaar lijken dicht bij elkaar, zodat de eerder gevonden clusters ook zichtbaar worden in de plot. Het is een handig hulpmiddel om patronen in de data te verkennen.

Het blijft echter een visualisatie: lokale relaties (cellen die erg op elkaar lijken) worden goed weergegeven, maar de grotere, globale structuur is minder betrouwbaar. Gebruik UMAP of tSNE daarom vooral om een indruk van de data te krijgen, maar niet om er alleen op basis van de plot biologische conclusies te trekken.




Figure 8: DimPlot: Op de x-as wordt `umap_1` geplot en op de y-as wordt `umap_2` geplot. Elke stip representeert een individuele cel. De kleur geeft aan bij welk cluster deze cel hoort.

Het vinden van differentieel tot expressie gebrachte kenmerken (clusterbiomarkers)

Vervolgens kunnen er voor elke cluster genen gezocht worden die duidelijk meer (of minder) tot expressie komen dan in andere cellen. Dit helpt om te bepalen welke genen een cluster kenmerken.

Toewijzen van celtype-identiteit aan clusters

Als laatste stap worden er bekende celtypen gekoppeld aan de clusters.

Conclusie en discussie

In deze analyse is aangetoond dat het Seurat-pakket effectief kan worden gebruikt voor het verwerken, analyseren en interpreteren van single-cell RNA-seq data. Door middel van een gestandaardiseerde workflow (bestaande uit kwaliteitscontrole, normalisatie, dimensiereductie, clustering en markeranalyse) konden verschillende celpopulaties binnen de PBMC-dataset succesvol worden geïdentificeerd.




Figure 9: ViolinPlot: Het expressielevel van het gen MS4A1 wordt per cluster weergegeven. In cluster 3 komt dit gen het meest tot expressie.




Figure 10: FeaturePlot:Op de x-as staat umap_1 en op de y-as staat umap_2. De expressie van MS4A1 wordt aangegeven in het paars.




Figure 12: DimPlot: Op de x-as staat umap_1 en op de y-as staat umap_2. De clusters zijn aangegeven met verschillende kleuren en in de clusters staan de celtype namen van de desbetreffende cluster.

De kwaliteitscontrole liet zien dat filtering op basis van het aantal genen per cel en het percentage mitochondriale genexpressie essentieel is om ruis en slechte kwaliteit cellen te verwijderen. Vervolgens zorgde normalisatie ervoor dat expressiewaarden tussen cellen vergelijkbaar werden gemaakt. Door selectie van variabele genen en toepassing van PCA werd de dimensie van de dataset gereduceerd, waarbij de belangrijkste bronnen van variatie behouden bleven.

De clusteringanalyse, gebaseerd op de eerste tien principal components, resulteerde in duidelijk gescheiden clusters zoals zichtbaar in de UMAP-visualisatie (zie figuur 8 en 12). Deze clusters konden biologisch geïnterpreteerd worden door middel van differentiële genexpressieanalyse. Bekende marker genen, zoals *MS4A1* voor B-cellen, bevestigden dat de clusters overeenkomen met verwachte immuunceltypen zoals T-cellen, monocyt, NK-cellen en dendritische cellen.

Hoewel de resultaten biologisch plausibel zijn, zijn er enkele beperkingen. Ten eerste is de keuze van parameters, zoals het aantal PC's en de clusteringresolutie, deels subjectief en kan deze de uitkomst beïnvloeden. Daarnaast zijn technieken zoals UMAP vooral bedoeld voor visualisatie en geven ze niet altijd een volledig betrouwbaar beeld van de globale structuur van de data. Verder is de annotatie van celtypen afhankelijk van bekende marker genen en kan dit leiden tot onzekerheid bij minder goed gekarakteriseerde celpopulaties.

Samenvattend laat deze studie zien dat Seurat een krachtig en flexibel hulpmiddel is voor single-cell RNA-seq analyse. De combinatie van statistische methoden en biologische interpretatie maakt het mogelijk om complexe heterogeniteit binnen celpopulaties inzichtelijk te maken, mits de resultaten kritisch worden geëvalueerd en ondersteund met biologische kennis.