

02_seurat_data_integration_tutorial

2026-03-25

Deelvraag

Hoe kan data-integratie met Seurat worden toegepast om biologische verschillen tussen condities in single-cell RNA-seq data te analyseren?

Methode

In deze analyse is gebruikgemaakt van het Seurat-pakket in R voor de integratie en analyse van single-cell RNA-seq data. De workflow is gebaseerd op de officiële Seurat tutorial *“Introduction to scRNA-seq integration”*.

De gebruikte dataset bestaat uit humane perifere bloed mononucleaire cellen (PBMC's) onder twee condities:

- controlecellen (CTRL)
- interferon-gestimuleerde cellen (STIM)

Het doel van de analyse is om deze datasets te integreren zodat cellen van hetzelfde type, maar uit verschillende condities, samen clusteren. Hierdoor kunnen verschillen in genexpressie tussen condities betrouwbaar worden onderzocht, zonder dat technische variatie of batch-effecten de interpretatie verstoren.

De analyse bestaat uit de volgende stappen:

- standaard analyse zonder integratie
- integratie van datasets
- identificatie van geconserveerde markers
- analyse van differentiële genexpressie
- vergelijking met SCTransform-integratie

Resultaten

Analyse zonder data integratie

Eerst is de dataset geanalyseerd zonder data-integratie. Hierbij worden cellen uit beide condities gezamenlijk geanalyseerd, zonder correctie voor mogelijke technische of conditionele verschillen.

De genexpressiewaarden worden eerst genormaliseerd zodat cellen onderling vergelijkbaar zijn. Vervolgens worden de meest variabele genen geselecteerd, omdat deze het meest informatief zijn voor het onderscheiden van celtypes. Met behulp van principal component analysis (PCA) wordt de complexe genexpressiedata samengevat in een beperkt aantal dimensies die de belangrijkste variatie in de data beschrijven. Deze dimensies worden gebruikt om cellen te groeperen in clusters.




Figure 1: Elke stip representeert een individuele cel. Cellen zijn gekleurd op basis van conditie (CTRL vs STIM). De figuur laat zien dat cellen deels clusteren op basis van stimulatieconditie in plaats van biologisch celtype, wat wijst op de aanwezigheid van batch- of conditie-effecten.

Tot slot wordt UMAP toegepast, een techniek die hoge-dimensionale data visualiseert in twee dimensies, waardoor patronen en clusters van cellen zichtbaar worden.

Zoals te zien is in figuur 1 clusteren cellen gedeeltelijk op basis van conditie in plaats van biologisch celtype. Dit wijst erop dat conditionele verschillen een sterke invloed hebben op de clustering, wat de interpretatie van biologische verschillen bemoeilijkt.

Data-integratie

Om de invloed van conditionele en technische variatie te verminderen, wordt data-integratie toegepast. Hierbij worden datasets uit verschillende condities gecombineerd zodat cellen met vergelijkbare biologische eigenschappen bij elkaar worden geplaatst.

De integratie wordt uitgevoerd met behulp van canonical correlation analysis (CCA). Deze methode identificeert gedeelde patronen tussen datasets en corrigeert verschillen die niet biologisch van aard zijn.

Na integratie wordt opnieuw een buurtnetwerk berekend, clustering uitgevoerd en een UMAP-visualisatie gemaakt op basis van de geïntegreerde data.




Figure 2: Stim: Elke cel wordt weergegeven als een stipje. Controle is rood en gestimuleerde cellen zijn blauw. Seurat_annotations: Elke cel wordt weergegeven als een stipje. Er zijn 13 clusters weergegeven met elk een eigen kleur.

Zoals weergegeven in figuur 2 clusteren cellen na integratie voornamelijk op basis van biologisch celtype en niet langer op basis van conditie. Dit laat zien dat de integratiestap succesvol is in het verwijderen van ongewenste variatie, waardoor cellen uit verschillende condities beter vergelijkbaar zijn.




Figure 3: CTRLSTIM: Controle en gestimuleerde cellen worden naast elkaar weergegeven. Elke cel wordt weergegeven als een stipje. Er zijn 16 clusters weergegeven met elk een eigen kleur.

Figuur 3 toont de verdeling van celtypes per conditie. Hieruit blijkt dat dezelfde celtypes aanwezig zijn in beide condities en vergelijkbaar zijn gepositioneerd in de UMAP. Dit bevestigt dat de integratie correct is uitgevoerd en dat biologische interpretaties betrouwbaar zijn.

Geconserveerde celtypemarkers

Na het vaststellen van betrouwbare clusters worden geconserveerde celtypemarkers geïdentificeerd. Dit zijn genen die consistent verhoogd tot expressie komen binnen een specifiek celtyp, ongeacht de conditie.

Door deze markers te identificeren kunnen clusters worden gekoppeld aan bekende celtypes, zoals T-cellen, B-cellen en monocyt. Dit is essentieel om de biologische betekenis van de clusters te begrijpen.

De gevonden markers bevestigen dat de clustering gebaseerd is op biologische verschillen tussen celtypes en niet op technische variatie, wat de betrouwbaarheid van de analyse ondersteunt.

Visualisatie van marker genen

De expressie van geselecteerde marker genen wordt gevisualiseerd met behulp van een dotplot (figuur 4). In deze visualisatie wordt per celtyp weergegeven in welke mate specifieke genen tot expressie komen.

De grootte van de stippen geeft het percentage cellen weer waarin een gen tot expressie komt, terwijl de kleur het relatieve expressieniveau aangeeft.

De dotplot laat zien dat specifieke marker genen consistent tot expressie komen binnen bepaalde celtypes, ongeacht de conditie. Dit bevestigt dat de clustering biologisch betekenisvol is en dat de geïdentificeerde celtypes betrouwbaar zijn.

Daarnaast ondersteunt dit resultaat dat de integratie succesvol is uitgevoerd, omdat de expressiepatronen overeenkomen tussen de twee condities.

Differentieel tot expressie gebrachte genen

Na data-integratie kunnen verschillen in genexpressie tussen condities op een betrouwbare manier worden geanalyseerd. Hierbij wordt onderzocht welke genen significant meer of minder tot expressie komen in gestimuleerde cellen ten opzichte van controlecellen, binnen hetzelfde celtyp.

Om dit mogelijk te maken worden celtyp en conditie gecombineerd tot één nieuwe identiteit. Hierdoor kunnen bijvoorbeeld gestimuleerde B-cellen direct worden vergeleken met controle B-cellen. Dit is essentieel, omdat genexpressie sterk kan variëren tussen verschillende celtypes.

Met behulp van de functie FindMarkers worden genen geïdentificeerd die significant verschillend tot expressie komen tussen deze groepen. Deze genen worden aangeduid als differentieel tot expressie gebrachte genen.

De analyse laat zien dat interferon-respons genen, zoals ISG15 en CXCL10, sterk verhoogd zijn in gestimuleerde cellen. Dit is biologisch verklaarbaar, aangezien interferon een belangrijke rol speelt in de antivirale afweer en de expressie van specifieke responsgenen activeert.

Dit resultaat geeft direct antwoord op de onderzoeksvraag: door data-integratie toe te passen kunnen verschillen in genexpressie tussen condities worden geïdentificeerd op een manier die niet verstoord wordt door technische variatie.

Hiermee wordt aangetoond dat data-integratie essentieel is voor het betrouwbaar analyseren van biologische effecten in single-cell RNA-seq data.




Figure 4: DotPlot: Op de x-as zijn de verschillende features weergegeven. Op de y-as zijn de verschillende celtypes weergegeven, gescheiden in gestimuleerde cellen en de controle cellen. De grootte van de dots geven aan hoeveel procent expressie van de features aanwezig zijn in de celtype, waarbij grotere dots een hoger percentage betekend. Rode dots zijn van de gestimuleerde cellen en blauwe dots zijn van de controlegroep.

SCTransform-integratie

Naast de standaard integratiemethode wordt ook SCTransform toegepast als alternatieve normalisaties-trategie. Deze methode maakt gebruik van een statistisch model om technische variatie, zoals verschillen in sequencing depth, expliciet te modelleren en te corrigeren.

Na normalisatie met SCTransform worden opnieuw PCA en UMAP toegepast om de data te visualiseren en celclusters te identificeren.

De resultaten, weergegeven in figuur 5, tonen een vergelijkbare clustering van celtypes als bij de eerdere integratiemethode. Cellen groeperen opnieuw op basis van biologisch celtype en niet op basis van conditie.

Dit suggereert dat de bevindingen robuust zijn en niet afhankelijk van één specifieke analysemethode. Zowel CCA-gebaseerde integratie als SCTransform leveren consistente en biologisch interpreteerbare resultaten.




Figure 5: UMAP-visualisatie na SCTransform-normalisatie. Cellen zijn gekleurd op basis van conditie en celtype. De figuur laat zien dat SCTransform een alternatieve methode biedt om technische variatie te corrigeren.

Conclusie en discussie

Deze analyse laat zien dat data-integratie met Seurat essentieel is voor het betrouwbaar analyseren van single-cell RNA-seq data uit verschillende condities. Zonder integratie clusteren cellen voornamelijk op basis van conditie, terwijl na integratie cellen correct groeperen op basis van biologisch celtype.

Door deze integratie kunnen verschillen in genexpressie tussen condities op een betrouwbare manier worden onderzocht. Dit maakt het mogelijk om biologisch relevante processen te identificeren, zoals de activatie van interferon-respons genen in gestimuleerde cellen.

Een belangrijke beperking is dat de resultaten afhankelijk zijn van de gekozen integratiemethode en de gebruikte parameters. Daarnaast bestaat het risico op overcorrectie, waarbij echte biologische verschillen deels worden weggefilterd. Ook kunnen zeldzame celtypes minder goed worden herkend of samengevoegd met andere clusters.

Samenvattend biedt Seurat een krachtige en flexibele methode voor de analyse van multi-condition single-cell data. Dit is met name relevant voor biologisch onderzoek waarin verschillen tussen behandelingen of condities centraal staan, zoals bij infectie- of immuunrespons studies.