

08_e6.5_data_laden

2025-11-27

Deelvraag: Hoe ziet de single-cell RNA-seq dataset van muizenembryo's op ontwikkelingsstadium E6.5 eruit en welke cellulaire clusters kunnen op basis van genexpressie worden onderscheiden?

Methode

Voor deze analyse is er gebruikgemaakt van single-cell RNA-seq data afkomstig van muizenembryo's op ontwikkelingsstadium E6.5. De data bestaat uit een genexpressiematrix waarin per cel het aantal RNA-moleculen per gen is vastgelegd, aangevuld met metadata over cellen en genen.

De analyse is uitgevoerd met het Seurat-pakket in R en omvat de volgende stappen: kwaliteitscontrole, normalisatie, selectie van variabele genen, dimensionale reductie, clustering en identificatie van marker-genen.

Voor de kwaliteitscontrole zijn per cel drie belangrijke kenmerken berekend: het aantal gedetecteerde genen (nFeature_RNA), het totaal aantal RNA-moleculen (nCount_RNA) en het percentage mitochondriaal RNA. Cellen met een extreem laag aantal genen (mogelijk lege druppels), een zeer hoog aantal genen (mogelijke doublets) of een verhoogd mitochondriaal RNA-percentages (indicatief voor beschadigde cellen) zijn verwijderd.

Na filtering is de data genormaliseerd met log-normalisatie, waarbij de totale expressie per cel wordt geschaald naar 10.000 gevolgd door een log-transformatie. Vervolgens zijn de 2000 meest variabele genen geselecteerd, omdat deze het meest bijdragen aan biologische verschillen tussen cellen.

Met behulp van principal component analysis (PCA) is de hoge-dimensionale data gereduceerd tot een beperkt aantal dimensies. Op basis van een elbowplot zijn de eerste tien principal components geselecteerd voor verdere analyse. Deze componenten zijn gebruikt om een buurtnetwerk te construeren, waarop clustering is toegepast. Tot slot zijn de clusters gevisualiseerd met UMAP.

Resultaten

In de volgende sectie worden de resultaten van deze stappen stap voor stap besproken.

Kwaliteitscontrole en filtering

De kwaliteitscontrole (figuur 1 en 2) laat zien dat de meeste cellen binnen een realistisch bereik vallen voor zowel het aantal genen als het aantal RNA-moleculen per cel. Daarnaast is het percentage mitochondriaal RNA over het algemeen laag, wat wijst op een goede celkwaliteit.

De scatterplots (figuur 2) tonen een sterke positieve correlatie tussen het aantal RNA-moleculen en het aantal gedetecteerde genen, wat biologisch verwacht is. Er is geen sterke relatie tussen mitochondriaal RNA en totale expressie, wat suggereert dat er geen systematische kwaliteitsproblemen aanwezig zijn.

Op basis van deze observaties zijn cellen gefilterd met de volgende criteria:

- minimaal 200 en maximaal 4000 genen per cel
Cellen met minder dan 200 of meer dan 4000 gedetecteerde genen zijn verwijderd. Lage waarden kunnen wijzen op lege druppels of cellen van lage kwaliteit, terwijl hoge waarden kunnen duiden op doublets, waarbij meerdere cellen als één cel zijn gemeten. De gekozen drempels zijn gebaseerd op de verdeling van de data en sluiten aan bij gebruikelijke waarden voor single-cell RNA-seq analyse.
- minder dan 7% mitochondriaal RNA
Cellen met een mitochondriaal RNA-percentage hoger dan 7% zijn verwijderd. Deze drempel is gekozen op basis van de kwaliteitscontroleplots, waarin te zien is dat de meeste cellen onder deze waarde vallen. Een iets hogere drempel is passend voor vroege embryonale cellen, waarin relatief meer mitochondriaal RNA kan voorkomen. De gekozen drempel ligt binnen de gebruikelijke range van 5–8% voor single-cell RNA-seq data.

Deze filtering zorgt ervoor dat alleen hoogwaardige cellen worden meegenomen in de verdere analyse.




Figure 1: Kwaliteitscontrole van E6.5 single-cell data: Violinplots van (links) het aantal gedetecteerde genen per cel, (midden) het totaal aantal RNA-moleculen per cel en (rechts) het percentage mitochondriaal RNA. Elke stip representeert een individuele cel.

Normaliseren van de gegevens

Na filtering is de data genormaliseerd door de totale expressie per cel te schalen naar 10.000 en vervolgens een log-transformatie toe te passen. Hierdoor worden expressiewaarden tussen cellen onderling vergelijkbaar. Dit zorgt ervoor dat cellen met veel RNA niet automatisch domineren in de analyse.




Figure 2: Relatie tussen kwaliteitskenmerken per cel: Scatterplots waarin links het percentage mitochondriaal RNA is uitgezet tegen het totaal aantal RNA-moleculen per cel, en rechts het aantal gedetecteerde genen tegen het totaal aantal RNA-moleculen. Elke stip representeert één cel.

Kenmerkselectie

Vervolgens zijn de 2000 meest variabele genen geselecteerd. Deze genen dragen het sterkst bij aan verschillen tussen cellen en vormen de basis voor verdere analyse.




Figure 3: Selectie van variabele genen: De gemiddelde genexpressie is uitgezet tegen de gestandaardiseerde variantie. De 2000 meest variabele genen zijn rood weergegeven; de vijf genen met de hoogste variatie zijn gelabeld.

De gegevens schalen

De gemiddelde expressie over de cellen wordt op 0 gesteld, ook wordt de variantie over de cellen op 1 gesteld.

Lineaire dimensionale reductie uitvoeren

Met behulp van principal component analysis (PCA) is de hoge-dimensionale genexpressiedata samengevat in een kleiner aantal hoofdcomponenten. Omdat er duizenden genen tegelijk worden gemeten, is de data erg complex. PCA wordt gebruikt om deze complexiteit samen te vatten in een kleiner aantal overzichtelijke componenten die de belangrijkste verschillen tussen cellen weergeven.

Dimensionaliteit

De elbowplot (figuur 7) laat zien dat de grootste bijdrage aan de variantie wordt geleverd door de eerste tien principal components. Daarom zijn deze componenten gebruikt voor verdere analyse.




Figure 4: Genbijdragen aan de eerste principal component (PC1): Visualisatie van de genen die het sterkst bijdragen aan PC1.




Figure 5: PCA-plot van cellen: Projectie van cellen op de eerste twee principal components, waarbij elke stip een individuele cel representeert.

PC_1




Figure 6: Heatmap van genexpressie geassocieerd met PC1: Heatmap van genen die bijdragen aan PC1, waarbij rijen genen en kolommen cellen representeren. Paars is een lage PCA-score, geel is een hoge PCA-score. Deze heatmap laat zien welke genen bijdragen aan de belangrijkste verschillen tussen cellen.




Figure 7: Elbowplot voor bepaling van het aantal principal components: De standaarddeviatie van opeenvolgende principal components, waarbij het knikpunt rond PC9–PC10 aangeeft welke componenten informatief zijn voor verdere analyse.

Clusteren

Op basis van de eerste tien principal components zijn cellen geclusterd met behulp van een graf-gebaseerde methode. De gekozen resolutie (0.5) resulteerde in vijf duidelijke clusters.

Niet-lineaire dimensionale reductie uitvoeren (UMAP/tSNE)

Deze clusters zijn gevisualiseerd met behulp van UMAP (figuur 8). De UMAP laat zien dat cellen zich groeperen in goed gescheiden clusters, wat wijst op duidelijke verschillen in genexpressie tussen celpopulaties.




Figure 8: UMAP-visualisatie van E6.5 cellen: Projectie van cellen in een tweedimensionale ruimte, waarbij kleuren de verschillende clusters weergeven. Elke stip representeert één cel.

Het vinden van differentieel tot expressie gebrachte kenmerken (clusterbiomarkers)

Om de biologische betekenis van de clusters te bepalen, zijn de top 5 differentieel tot expressie gebrachte genen per cluster geanalyseerd. Deze genen geven inzicht in de identiteit en functie van de cellen binnen elk cluster.

De resultaten laten zien dat elk cluster een specifiek expressieprofiel heeft dat overeenkomt met bekende celtypen in het E6.5 muizenembryo:

- Cluster 0 – Primitive streak / nascent mesoderm.
Dit cluster wordt gekenmerkt door expressie van genen zoals *Pbx1*, *Aff3*, *Tenm3* en *Igf1r*. Deze genen

zijn betrokken bij transcriptieregulatie en vroege differentiatieprocessen en passen bij cellen in de primitive streak, waar mesodermvorming plaatsvindt.

- Cluster 1 – Epiblast.
Genen zoals *Dnmt3b*, *Pim2* en *Zfp608* zijn verhoogd tot expressie in dit cluster. Deze genen zijn geassocieerd met proliferatie en epigenetische regulatie, wat past bij relatief ongedifferentieerde epiblastcellen.
- Cluster 2 – Visceral endoderm.
Dit cluster toont sterke expressie van genen zoals *Dab2*, *Amn* en *Cubn*, die bekend zijn voor hun rol in nutriëntopname en endodermale functies. Dit bevestigt de identificatie als visceraal endoderm.
- Cluster 3 – Extra-embryonic ectoderm.
De expressie van genen zoals *Elf5*, *Sfmbt2* en *Esrrb* wijst op extra-embryonale cellen. *Elf5* is een bekende marker voor trophoctoderm en extra-embryonale structuren.
- Cluster 4 – Endotheel / vasculaire cellen.
Dit cluster wordt gekenmerkt door expressie van genen zoals *Epas1* en *Lama1*, die betrokken zijn bij bloedvatvorming en vasculaire ontwikkeling.

Opvallend is dat veel van de geïdentificeerde features intronische reads bevatten (bijv. *Tenm3-intron*, *Aff3-intron*), wat kan wijzen op actieve transcriptie en de aanwezigheid van ongespliced RNA-moleculen. Dit is gebruikelijk in single-cell RNA-seq datasets en kan aanvullende informatie geven over transcriptiedynamiek.

De combinatie van deze marker-genen en de ruimtelijke scheiding van clusters in de UMAP bevestigt dat de geïdentificeerde clusters overeenkomen met biologisch relevante celtypen binnen het E6.5 muizenembryo. Deze annotatie sluit aan bij bekende literatuur over vroege muisembryogenese, waarin deze celtypen rond E6.5 worden beschreven.

Conclusie

De single-cell RNA-seq analyse van muizenembryo's op ontwikkelingsstadium E6.5 laat zien dat de dataset bestaat uit meerdere duidelijk te onderscheiden celpopulaties. Na kwaliteitscontrole en filtering konden vijf clusters worden geïdentificeerd, waaronder epiblast, mesodermale populaties, visceraal endoderm, extra-embryonaal ectoderm en endotheelcellen.

Door middel van markeranalyse zijn deze clusters gekoppeld aan biologisch relevante celtypen, waaronder epiblast, mesodermale populaties, visceraal endoderm, extra-embryonaal ectoderm en endotheelcellen. Dit weerspiegelt de complexe cellulaire diversiteit en differentiatieprocessen die plaatsvinden tijdens vroege embryonale ontwikkeling bij de muis.

De combinatie van clustering en markeranalyse maakt het mogelijk om de structuur van het muizenembryo op cellulair niveau te reconstrueren. Deze resultaten vormen een belangrijke basis voor verdere analyses, zoals het bestuderen van ontwikkelingsroutes en genregulatie tijdens muisembryogenese.




Figure 9: Expressie van Tenm3-intron per cluster: Violinplot waarin de expressieniveaus van het gen Tenm3-intron per cluster worden weergegeven.




Figure 10: Ruimtelijke expressie van Tenm3-intron: UMAP-plot waarin de expressie van Tenm3-intron per cel is weergegeven, waarbij hogere expressie wordt aangegeven door een intensere kleur.




Figure 11: Heatmap van cluster-specifieke markergenen: Heatmap van de vijf meest differentieel tot expressie gebrachte genen per cluster, waarbij geel een hoge en paars een lage expressie aangeeft.




Figure 12: UMAP-visualisatie van E6.5 cellen: Projectie van cellen in een tweedimensionale ruimte, waarbij kleuren de verschillende clusters weergeven. Elke stip representeert één cel. De namen van de clusters zijn weergegeven.