

08_e6.5_data_laden

2025-11-27

In deze Rmarkdown wordt de data van tijdstip E6.5 gebruikt. De data is afkomstig van muizenembryo's.




Figure 1: Vioolplot: Er zijn drie vioolplots naast elkaar weergegeven. In alle drie de vioolplots wordt op de x-as de dataset E6.5 weergegeven. Elk stipje is een cel. Links wordt op de y-as het aantal unieke features weergegeven. In het midden staat op de y-as het aantal RNA binnen de cel. Rechts wordt op de y-as het percentage mitochondriale RNA weergegeven.

Normaliseren van de gegevens

De data wordt genormaliseerd door de totale expressie van elke cel om te zetten naar 10.000 en vervolgens een log-transformatie te nemen (het getal weer kleiner maken). Hierdoor kunnen de getallen per cel met elkaar vergeleken worden.




Figure 2: FeatureScatterplots: Er zijn twee scatterplots naast elkaar weergegeven, bij beide scatterplots staat op de x-as het aantal RNA binnen de cel. Elk stipje is een cel. Links is op de y-as het percentage mitochondriale RNA weergegeven. Rechts is op de y-as het aantal unieke features per cel weergegeven.

Kenmerkselectie

In figuur 3 zijn de 2000 genen met de meeste variërende kenmerken zijn rood gekleurd en de 10 meest variërende genen worden aangegeven met hun naam.




Figure 3: VariableFeaturePlot: Op de x-as wordt de gemiddelde expressie weergegeven. Op de y-as wordt de standaard variantie weergegeven. De 2000 genen met de meest variërende kenmerken zijn rood gekleurd en de 10 cellen met de meest variërende genen zijn aangegeven met hun naam.

De gegevens schalen

De gemiddelde expressie over de cellen wordt op 0 gesteld, ook wordt de variantie over de cellen op 1 gesteld.

Lineaire dimensionale reductie uitvoeren

Met behulp van principal component analyses (PCA) worden er van de oude variabelen, nieuwe variabelen gemaakt door lineaire combinaties te maken. Hieruit ontstaan enkele hoofdcomponenten (PC's). PC1 dekt het grootste deel van de variatie binnen de data. PC2 dekt daarna het grootste deel, enzovoort.

Dimensionaliteit

Om ruis te voorkomen in verdere analyse wordt er gekeken hoeveel PC's meegenomen moeten worden. Hiervoor kan er gebruik gemaakt worden van een elbowplot. In deze plot worden de PC's op de x-as geplaatst




Figure 4: VizDimLoadings. De topgenen worden weergegeven die geassocieerd worden met PC1.




Figure 5: DimPlot, Op de x-as wordt PC1 geplott en op de y-as wordt PC2 geplott. Elke stip representeert een cel.




Figure 6: DimHeatmap, PC1 wordt weergegeven met de verschillende genen in de rijen, en verschillende cellen in de kolommen. Paars is een lage PCA-score, geel is een hoge PCA-score. Clusters worden hiermee gevisualiseerd

en de standaard deviatie op de y-as. Er ontstaat een soort van arm, waarbij de elleboog het keerpunt is. De PC's voor de elleboog worden meegenomen en de PC's na de elleboog worden niet meegenomen. Het verschil tussen de PC's na de elleboog is niet relevant genoeg om mee te nemen. In figuur 7 is de elleboog zichtbaar tussen 9 en 10.




Figure 7: ElbowPlot: Op de x-as staan de PC's en op de y-as staan de standaard deviatie.

Clusteren

Nadat de juiste PC's zijn gekozen (1-10), verdeelt Seurat de cellen in groepen (clusters). Het programma kijkt hiervoor welke cellen het meest op elkaar lijken en verbindt die in een netwerk. Vervolgens zoekt het naar dicht bij elkaar liggende groepjes cellen binnen dat netwerk. Met de resolutie-instelling kun je bepalen of je grotere, bredere groepen of juist kleinere, gedetailleerdere groepen krijgt. In dit geval is er gekozen voor een resolutie van 0.5.

Niet-lineaire dimensionale reductie uitvoeren (UMAP/tSNE)

Seurat kan technieken zoals UMAP en tSNE gebruiken om de data overzichtelijk weer te geven in twee dimensies. Deze methoden plaatsen cellen die op elkaar lijken dicht bij elkaar, zodat de eerder gevonden clusters ook zichtbaar worden in de plot. Het is een handig hulpmiddel om patronen in de data te verkennen. Het blijft echter een visualisatie: lokale relaties (cellen die erg op elkaar lijken) worden goed weergegeven, maar de grotere, globale structuur is minder betrouwbaar. UMAP of tSNE wordt daarom vooral gebruikt om een indruk van de data te krijgen, maar niet om op basis van de plot biologische conclusies te trekken.




Figure 8: DimPlot: Op de x-as wordt umap_1 geplott en op de y-as wordt umap_2 geplott. Elke stip representeert een cel. De kleur geeft aan bij welk cluster deze cel hoort.

Het vinden van differentieel tot expressie gebrachte kenmerken (clusterbiomarkers)

Vervolgens kunnen er voor elke cluster genen gezocht worden die duidelijk meer (of minder) tot expressie komen dan in andere cellen. Dit helpt om te bepalen welke genen een cluster kenmerken.




Figure 9: ViolinPlot: Het expressielevel van het gen Tenm3-intron wordt per cluster weergegeven. In cluster 3 komt dit gen het meest tot expressie.




Figure 10: FeaturePlot:Op de x-as staat `umap_1` en op de y-as staat `umap_2`. De expressie van *Tenm3*-intron wordt aangegeven in het paars.




Figure 11: DoHeatMap: Op de x-as worden de clusters weergegeven en op de y-as worden de verschillende markers weergegeven. De 10 belangrijkste markers worden per cluster weergegeven. De gele kleur geeft een hoge expressie van het gen aan en de paarse kleur een lage expressie.