

09_e7.5_data_laden

2025-11-27

Deelvraag: Hoe ziet de single-cell RNA-seq data van muizenembryo's op tijdstip E7.5 eruit en welke cellulaire clusters zijn hierin te onderscheiden?

Methode

Voor deze analyse is er gebruikgemaakt van single-cell RNA-seq data afkomstig van muizenembryo's op ontwikkelingsstadium E7.5. De data bestaat uit een genexpressiematrix waarin per cel het aantal RNA-moleculen per gen is vastgelegd, aangevuld met metadata over cellen en genen.

De analyse is uitgevoerd met het Seurat-pakket in R en omvat de volgende stappen: kwaliteitscontrole, normalisatie, selectie van variabele genen, dimensionale reductie, clustering en identificatie van marker-genen.

Voor de kwaliteitscontrole zijn per cel drie belangrijke kenmerken berekend: het aantal gedetecteerde genen (nFeature_RNA), het totaal aantal RNA-moleculen (nCount_RNA) en het percentage mitochondriaal RNA. Cellen met een extreem laag aantal genen (mogelijk lege druppels), een zeer hoog aantal genen (mogelijke doublets) of een verhoogd mitochondriaal RNA-percentage (indicatief voor beschadigde cellen) zijn verwijderd. De gekozen drempels zijn gebaseerd op de verdeling van de data en sluiten aan bij gebruikelijke waarden voor single-cell RNA-seq analyse.

Na filtering is de data genormaliseerd met log-normalisatie, waarbij de totale expressie per cel wordt geschaald naar 10.000 gevolgd door een log-transformatie. Vervolgens zijn de 2000 meest variabele genen geselecteerd, omdat deze het meest bijdragen aan biologische verschillen tussen cellen.

Met behulp van principal component analysis (PCA) is de hoge-dimensionale data gereduceerd tot een beperkt aantal dimensies. Op basis van een elbowplot zijn de eerste tien principal components geselecteerd voor verdere analyse. Deze componenten zijn gebruikt om een buurtnetwerk te construeren, waarop clustering is toegepast. Tot slot zijn de clusters gevisualiseerd met UMAP.

Resultaten

In de volgende sectie worden de resultaten van deze stappen stap voor stap besproken.

Kwaliteitscontrole en filtering

De kwaliteitscontrole (figuur 1 en 2) laat zien dat de meeste cellen binnen een realistisch bereik vallen voor zowel het aantal genen als het aantal RNA-moleculen per cel. Daarnaast is het percentage mitochondriaal RNA over het algemeen laag, wat wijst op een goede celkwaliteit.

De scatterplots (figuur 2) tonen een sterke positieve correlatie tussen het aantal RNA-moleculen en het aantal gedetecteerde genen, wat biologisch verwacht is. Er is geen sterke relatie tussen mitochondriaal RNA en totale expressie, wat suggereert dat er geen systematische kwaliteitsproblemen aanwezig zijn.

Op basis van deze observaties zijn cellen gefilterd met de volgende criteria:

- minimaal 200 en maximaal 6000 genen per cel
Cellen met minder dan 200 of meer dan 6000 gedetecteerde genen zijn verwijderd. Lage waarden kunnen wijzen op lege druppels of cellen van lage kwaliteit, terwijl hoge waarden kunnen duiden op doublets. Voor deze dataset is een hogere bovengrens gebruikt, omdat cellen in dit ontwikkelingsstadium gemiddeld meer genen tot expressie brengen.
- minder dan 6% mitochondriaal RNA
Cellen met een mitochondriaal RNA-percentage hoger dan 6% zijn verwijderd. Deze drempel is gekozen op basis van de kwaliteitscontroleplots, waarin te zien is dat de meeste cellen een laag mitochondriaal percentage hebben. Hogere waarden worden vaak geassocieerd met beschadigde of gestreste cellen en zijn daarom uitgesloten. De gekozen drempel ligt binnen de gebruikelijke range van 5–8% voor single-cell RNA-seq data.

Deze filtering zorgt ervoor dat alleen hoogwaardige cellen worden meegenomen in de verdere analyse.




Figure 1: Kwaliteitscontrole van E7.5 single-cell data: Violinplots van (links) het aantal gedetecteerde genen per cel, (midden) het totaal aantal RNA-moleculen per cel en (rechts) het percentage mitochondriaal RNA. Elke stip representeert een individuele cel.

Normaliseren van de gegevens

Na filtering is de data genormaliseerd door de totale expressie per cel te schalen naar 10.000 en vervolgens een log-transformatie toe te passen. Hierdoor worden expressiewaarden tussen cellen onderling vergelijkbaar. Dit zorgt ervoor dat cellen met veel RNA niet automatisch domineren in de analyse.




Figure 2: Relatie tussen kwaliteitskenmerken per cel: Scatterplots waarin links het percentage mitochondriaal RNA is uitgezet tegen het totaal aantal RNA-moleculen per cel, en rechts het aantal gedetecteerde genen tegen het totaal aantal RNA-moleculen. Elke stip representeert één cel.

Kenmerkselectie

Vervolgens zijn de 2000 meest variabele genen geselecteerd. Deze genen dragen het sterkst bij aan verschillen tussen cellen en vormen de basis voor verdere analyse.




Figure 3: Selectie van variabele genen: De gemiddelde genexpressie is uitgezet tegen de gestandaardiseerde variantie. De 2000 meest variabele genen zijn rood weergegeven; de tien genen met de hoogste variatie zijn gelabeld.

De gegevens schalen

De gemiddelde expressie over de cellen wordt op 0 gesteld, ook wordt de variantie over de cellen op 1 gesteld.

Lineaire dimensionale reductie uitvoeren

Met behulp van principal component analysis (PCA) is de hoge-dimensionale genexpressiedata samengevat in een kleiner aantal hoofdcomponenten. Omdat er duizenden genen tegelijk worden gemeten, is de data erg complex. PCA wordt gebruikt om deze complexiteit samen te vatten in een kleiner aantal overzichtelijke componenten die de belangrijkste verschillen tussen cellen weergeven.

Dimensionaliteit

De elbowplot (figuur 7) laat zien dat de grootste bijdrage aan de variantie wordt geleverd door de eerste acht principal components. Daarom zijn deze componenten gebruikt voor verdere analyse.




Figure 4: Genbijdragen aan de eerste principal component (PC1): Visualisatie van de genen die het sterkst bijdragen aan PC1.




Figure 5: PCA-plot van cellen: Projectie van cellen op de eerste twee principal components, waarbij elke stip een individuele cel representeert.




Figure 6: Heatmap van genexpressie geassocieerd met PC1: Heatmap van genen die bijdragen aan PC1, waarbij rijen genen en kolommen cellen representeren. Paars is een lage PCA-score, geel is een hoge PCA-score. Deze heatmap laat zien welke genen bijdragen aan de belangrijkste verschillen tussen cellen.




Figure 7: Elbowplot voor bepaling van het aantal principal components: De standaarddeviatie van opeenvolgende principal components, waarbij het knikpunt rond PC7–PC8 aangeeft welke componenten informatief zijn voor verdere analyse.

Clusteren

Op basis van de eerste acht principal components zijn cellen geclusterd met behulp van een graf-gebaseerde methode. De gekozen resolutie (0.3) resulteerde in elf clusters.

Niet-lineaire dimensionale reductie uitvoeren (UMAP/tSNE)

Deze clusters zijn gevisualiseerd met behulp van UMAP (figuur 8). De UMAP laat zien dat cellen zich groeperen in goed gescheiden clusters, wat wijst op duidelijke verschillen in genexpressie tussen celpopulaties.




Figure 8: UMAP-visualisatie van E7.5 cellen: Projectie van cellen in een tweedimensionale ruimte, waarbij kleuren de verschillende clusters weergeven. Elke stip representeert één cel.

Het vinden van differentieel tot expressie gebrachte kenmerken (clusterbiomarkers)

Om de biologische betekenis van de clusters te bepalen, zijn de top 5 differentieel tot expressie gebrachte genen per cluster geanalyseerd. Deze genen geven inzicht in de identiteit van de cellen.

De resultaten laten zien dat elk cluster een specifiek expressieprofiel heeft dat overeenkomt met bekende celtypen in het E7.5 muizenembryo:

- Cluster 0 – Epiblast / vroeg mesoderm. Gekenmerkt door genen zoals *Caln1*, *Pim2* en *Ror1*, die passen bij vroege, nog weinig gedifferentieerde cellen.

- Cluster 1 – Paraxiaal mesoderm. Expressie van *Dll1* en *Pcdh19* wijst op segmentatieprocessen en vroege mesodermontwikkeling.
- Cluster 2 – Lateraal mesoderm / mesenchym. Genen zoals *Ebf2*, *Itga9* en *Meis1* zijn betrokken bij mesenchymale differentiatie en celmigratie.
- Cluster 3 – Lateraal plaat mesoderm (cardiovasculair). Expressie van *Fendrr* en *Unc5c* wijst op vroege cardiovasculaire ontwikkeling.
- Cluster 4 – Posterior mesoderm / primitive streak. Genen zoals *Cdx1* en *Nkx1-2* zijn kenmerkend voor posterior patroonvorming en primitive streak activiteit.
- Cluster 5 – Hematopoëtische / erytroïde cellen. Sterke expressie van *Hbb* en *Runx1* duidt op bloedcelvorming.
- Cluster 6 – Definitief endoderm. Expressie van *Foxa1* en *Cpm* wijst op endodermale differentiatie.
- Cluster 7 – Extra-embryonaal ectoderm. Genen zoals *Elf5*, *Bmp8b* en *Wnt7b* zijn typisch voor extra-embryonale structuren.
- Cluster 8 – Visceraal endoderm. Expressie van *Apoa1*, *Rbp4* en *Ttr* wijst op nutriënttransport en endodermfunctie.
- Cluster 9 – Endotheel. Genen zoals *Thbd* en *Epas1* zijn betrokken bij bloedvatvorming.
- Cluster 10 – Angiogene endotheel. Expressie van *Flt4* en *Sox18* wijst op actieve angiogenese (vorming van nieuwe bloedvaten).

Deze resultaten tonen aan dat de dataset een breed scala aan celtypen bevat die kenmerkend zijn voor het E7.5 ontwikkelingsstadium.

Conclusie

De single-cell RNA-seq analyse van muizenembryo's op ontwikkelingsstadium E7.5 laat zien dat de dataset bestaat uit meerdere duidelijk te onderscheiden celpopulaties. In totaal werden elf clusters geïdentificeerd, waaronder epiblast, verschillende mesodermale populaties, endodermale cellen en endotheelcellen.

De markeranalyse bevestigt dat deze clusters overeenkomen met biologisch relevante celtypen die betrokken zijn bij vroege muizen embryonale ontwikkeling, zoals bloedvorming, vaatvorming en differentiatie van kiemlagen.

Deze resultaten tonen aan dat single-cell RNA-seq een krachtig hulpmiddel is om de complexiteit van muizen embryonale ontwikkeling op cellulair niveau te bestuderen.




Figure 9: Expressie van Tenm3-intron per cluster: Violinplot waarin de expressieniveaus van het gen Tenm3-intron per cluster worden weergegeven.




Figure 10: Ruimtelijke expressie van Tenm3-intron: UMAP-plot waarin de expressie van Tenm3-intron per cel is weergegeven, waarbij hogere expressie wordt aangegeven door een intensere kleur.




Figure 11: Heatmap van cluster-specifieke markergenen: Heatmap van de tien meest differentieel tot expressie gebrachte genen per cluster, waarbij geel een hoge en paars een lage expressie aangeeft.




Figure 12: UMAP-visualisatie van E7.5 cellen: Projectie van cellen in een tweedimensionale ruimte, waarbij kleuren de verschillende clusters weergeven. Elke stip representeert één cel. De namen van de clusters zijn weergegeven.