

10_e8.5_data_laden

2025-11-27

Deelvraag: Hoe ziet de single-cell RNA-seq dataset van muizenembryo's op ontwikkelingsstadium E8.5 eruit en welke cellulaire clusters kunnen op basis van genexpressie worden onderscheiden?

Methode

Voor deze analyse is er gebruikgemaakt van single-cell RNA-seq data afkomstig van muizenembryo's op ontwikkelingsstadium E8.5. De data bestaat uit een genexpressiematrix waarin per cel het aantal RNA-moleculen per gen is vastgelegd, aangevuld met metadata over cellen en genen.

De analyse is uitgevoerd met het Seurat-pakket in R en omvat de volgende stappen: kwaliteitscontrole, normalisatie, selectie van variabele genen, dimensionale reductie, clustering en identificatie van marker-genen.

Voor de kwaliteitscontrole zijn per cel drie kenmerken berekend: het aantal gedetecteerde genen (nFeature_RNA), het totaal aantal RNA-moleculen (nCount_RNA) en het percentage mitochondriaal RNA. De gekozen drempels zijn gebaseerd op de verdeling van de data en sluiten aan bij gebruikelijke waarden voor single-cell RNA-seq analyse.

Na filtering is de data genormaliseerd met log-normalisatie, waarbij de totale expressie per cel wordt geschaald naar 10.000 gevolgd door een log-transformatie. Vervolgens zijn de 2000 meest variabele genen geselecteerd.

Met behulp van principal component analysis (PCA) is de data gereduceerd tot een kleiner aantal dimensies. Op basis van een elbowplot zijn de eerste tien principal components geselecteerd voor verdere analyse. Deze componenten zijn gebruikt voor clustering en visualisatie met UMAP.

Resultaten

De kwaliteitscontrole (figuur 1 en 2) laat zien dat de meeste cellen binnen een realistisch bereik vallen voor zowel het aantal genen als het aantal RNA-moleculen per cel. Daarnaast is het percentage mitochondriaal RNA over het algemeen laag, wat wijst op een goede celkwaliteit.

De scatterplots (figuur 2) tonen een positieve correlatie tussen het aantal RNA-moleculen en het aantal gedetecteerde genen, wat biologisch verwacht is. Er is geen sterke relatie tussen mitochondriaal RNA en totale expressie, wat suggereert dat er geen systematische kwaliteitsproblemen aanwezig zijn.

Op basis van deze observaties zijn cellen gefilterd met de volgende criteria:

- minimaal 200 en maximaal 4000 genen per cel
Cellen met minder dan 200 of meer dan 4000 gedetecteerde genen zijn verwijderd om respectievelijk lage kwaliteit en mogelijke doublets uit te sluiten.

- minder dan 7% mitochondriaal RNA
Cellen met een hoger mitochondriaal RNA-percentage zijn verwijderd, omdat dit kan wijzen op beschadigde of gestreste cellen. De gekozen drempel ligt binnen de gebruikelijke range voor single-cell RNA-seq data.

Deze filtering zorgt ervoor dat alleen hoogwaardige cellen worden meegenomen in de verdere analyse.




Figure 1: Kwaliteitscontrole van E8.5 single-cell data: Violinplots van (links) het aantal gedetecteerde genen per cel, (midden) het totaal aantal RNA-moleculen per cel en (rechts) het percentage mitochondriaal RNA. Elke stip representeert een individuele cel.

Normaliseren van de gegevens

De data wordt genormaliseerd door de totale expressie van elke cel om te zetten naar 10.000 en vervolgens een log-transformatie te nemen (het getal weer kleiner maken). Hierdoor kunnen de getallen per cel met elkaar vergeleken worden.

Kenmerkselectie

Om de belangrijkste biologische variatie in de data te identificeren, zijn de 2000 meest variabele genen geselecteerd. Deze genen dragen het sterkst bij aan verschillen tussen cellen en vormen de basis voor de daaropvolgende dimensionale reductie.




Figure 2: Relatie tussen kwaliteitskenmerken per cel: Scatterplots waarin links het percentage mitochondriaal RNA is uitgezet tegen het totaal aantal RNA-moleculen per cel, en rechts het aantal gedetecteerde genen tegen het totaal aantal RNA-moleculen. Elke stip representeert één cel.




Figure 3: Selectie van variabele genen: De gemiddelde genexpressie is uitgezet tegen de gestandaardiseerde variantie. De 2000 meest variabele genen zijn rood weergegeven; de tien genen met de hoogste variatie zijn gelabeld.

De gegevens schalen

De gemiddelde expressie over de cellen wordt op 0 gesteld, ook wordt de variantie over de cellen op 1 gesteld.

Lineaire dimensionale reductie uitvoeren

Met behulp van principal component analysis (PCA) is de hoge-dimensionale genexpressiedata samengevat in een kleiner aantal hoofdcomponenten, waarbij elke component een deel van de totale variatie in de data beschrijft.




Figure 4: Genbijdragen aan de eerste principal component (PC1): Visualisatie van de genen die het sterkst bijdragen aan PC1.

Dimensionaliteit

Om ruis te voorkomen in verdere analyse wordt er gekeken hoeveel PC's meegenomen moeten worden. Hiervoor kan er gebruik gemaakt worden van een elbowplot. In deze plot worden de PC's op de x-as geplaatst en de standaard deviatie op de y-as. Er ontstaat een soort van arm, waarbij de elleboog het keerpunt is. De PC's voor de elleboog worden meegenomen en de PC's na de elleboog worden niet meegenomen. Het verschil tussen de PC's na de elleboog is niet relevant genoeg om mee te nemen. In figuur 7 is de elleboog zichtbaar tussen 9 en 10.




Figure 5: PCA-plot van cellen: Projectie van cellen op de eerste twee principal components, waarbij elke stip een individuele cel representeert.




Figure 6: Heatmap van genexpressie geassocieerd met PC1: Heatmap van genen die bijdragen aan PC1, waarbij rijen genen en kolommen cellen representeren. Paars is een lage PCA-score, geel is een hoge PCA-score. Clusters worden hiermee gevisualiseerd




Figure 7: Elbowplot voor bepaling van het aantal principal components: De standaarddeviatie van opeenvolgende principal components, waarbij het knippunt rond PC9–PC10 aangeeft welke componenten informatief zijn voor verdere analyse.

Clusteren

Op basis van de eerste tien principal components zijn cellen geclusterd met behulp van een graf-gebaseerde methode. De gekozen resolutie (0.5) bepaalt de mate van detail in de clustering, waarbij hogere waarden leiden tot meer, kleinere clusters.

Niet-lineaire dimensionale reductie uitvoeren (UMAP/tSNE)

Op basis van de eerste tien principal components zijn cellen geclusterd om groepen met vergelijkbare gen-expressiepatronen te identificeren. Deze clusters zijn vervolgens gevisualiseerd met behulp van UMAP, een niet-lineaire dimensionale reductiemethode.




Figure 8: UMAP-visualisatie van E8.5 cellen: Projectie van cellen in een tweedimensionale ruimte, waarbij kleuren de verschillende clusters weergeven. Elke stip representeert één cel.

Het vinden van differentieel tot expressie gebrachte kenmerken (clusterbiomarkers)

Om de biologische betekenis van de clusters te onderzoeken, zijn genen geïdentificeerd die specifiek tot expressie komen in individuele clusters. Deze markergenen geven inzicht in mogelijke celtypen of ontwikkelingsstadia.

```
## # A tibble: 180 x 7
```




Figure 9: Expressie van Ptn-intron per cluster: Violinplot waarin de expressieniveaus van het gen Ptn-intron per cluster worden weergegeven.




Figure 10: Ruimtelijke expressie van Ptn-intron: UMAP-plot waarin de expressie van Ptn-intron per cel is weergegeven, waarbij hogere expressie wordt aangegeven door een intensere kleur.




Figure 11: Heatmap van cluster-specifieke markergenen: Heatmap van de drie meest differentieel tot expressie gebrachte genen per cluster, waarbij geel een hoge en paars een lage expressie aanduidt.


```
## # Groups:  cluster [18]
##      p_val avg_log2FC pct.1 pct.2 p_val_adj cluster gene
##      <dbl>      <dbl> <dbl> <dbl>      <dbl> <fct>  <chr>
##  1 8.14e- 27      6.18 0.022 0.001 3.67e- 22 0      Wnt8b-exon
##  2 1.24e- 22      5.98 0.018 0      5.57e- 18 0      Kcna1-exon
##  3 5.47e-274      5.37 0.262 0.015 2.46e-269 0      Pax5-intron
##  4 3.83e- 30      5.31 0.023 0      1.73e- 25 0      Pdzhph1-exon
##  5 3.73e- 14      5.30 0.011 0      1.68e-  9 0      Egr2-intron
##  6 5.33e-162      5.23 0.142 0.005 2.40e-157 0      Pax5-exon
##  7 5.50e- 28      5.22 0.022 0      2.48e- 23 0      En1-intron
##  8 1.50e- 17      5.14 0.017 0.001 6.75e- 13 0      Prdm13-exon
##  9 1.98e- 20      5.07 0.017 0.001 8.89e- 16 0      Garem2-intron
## 10 3.25e-278      5.03 0.238 0.009 1.46e-273 0      Miat-exon
## # i 170 more rows
```




Figure 12: UMAP-visualisatie van E8.5 cellen: Projectie van cellen in een tweedimensionale ruimte, waarbij kleuren de verschillende clusters weergeven. Elke stip representeert één cel. De namen van de clusters zijn weergegeven.

Conclusie

De single-cell RNA-seq analyse van muizenembryo's op ontwikkelingsstadium E8.5 laat zien dat de dataset bestaat uit een groot aantal duidelijk te onderscheiden celpopulaties. In vergelijking met eerdere stadia

is de cellulaire diversiteit verder toegenomen, met onder andere neurale cellen, mesodermale populaties, endotheelcellen en immuuncellen.

De markeranalyse bevestigt dat deze clusters overeenkomen met biologisch relevante celtypen die betrokken zijn bij verdere differentiatie en orgaanvorming.

Deze resultaten tonen aan dat de complexiteit van het embryo toeneemt naarmate de ontwikkeling vordert, en onderstrepen de kracht van single-cell RNA-seq om deze dynamiek op cellulair niveau in kaart te brengen.