

14_monocle3_clusteren_en_trajectanalyse_e6.5

2026-03-29

Deelvraag: Hoe kan de data van tijdstip E6.5 worden ingelezen en geschikt gemaakt voor analyse in Monocle 3?

Methode

Voor deze analyse is gebruikgemaakt van het Monocle3 pakket in R om single-cell RNA-seq data van het tijdstip E6.5 te analyseren. De data bestaat uit een matrix met splicing events per cel.

De analyse bestaat uit de volgende stappen:

- inlezen van de event count matrix
- opzetten van een Monocle3 CellDataSet (CDS)
- dimensionale reductie met PCA en UMAP
- clustering van cellen
- identificatie van markergenen
- annotatie van clusters

Het groeperen en classificeren van de cellen

Verwerk de gegevens vooraf

Tijdens de preprocessing wordt de hoge-dimensionale data gereduceerd tot een beperkter aantal dimensies met behulp van principal component analysis (PCA). In Figuur 1 is een elbowplot weergegeven, waarin per principal component (PC) wordt aangegeven hoeveel variantie wordt verklaard. Het punt waar de curve afvlakt (de “elleboog”) geeft een geschikt aantal dimensies aan om te behouden voor verdere analyse.

Verlaag de dimensionaliteit en visualiseer de cellen

De voorbereiding is klaar, nu kunnen de cellen gevisualiseerd worden met behulp van een Uniform Manifold Approximation and Projection (UMAP). Een UMAP is een techniek voor dimensionale reductie. Het zet complexe biologische informatie om in een overzichtelijk figuur. Elke cel wordt weergegeven als een stipje. De positie van de cel wordt gebaseerd op de genen die actief zijn binnen de cel.

Na de preprocessing wordt de data geprojecteerd in een lage-dimensionale ruimte met behulp van UMAP. In Figuur 2 is te zien dat cellen zich groeperen in duidelijke clusters. Cellen met vergelijkbare genexpressie liggen dicht bij elkaar, wat wijst op overeenkomsten in celtype of toestand.

De UMAP kan ook gebruikt worden om de expressie van specifieke genen te visualiseren. In Figuur 3 is de expressie van het gen *Tenm3*-intron weergegeven. De kleurintensiteit geeft aan in welke mate dit gen tot expressie komt in verschillende cellen. Hieruit blijkt dat genexpressie niet uniform verdeeld is, maar geconcentreerd voorkomt in specifieke clusters.




Figure 1: Elbowplot: Op de x-as zijn 100 PCA components (PC's) weergegeven, op de y-as is de variantie van de PC's weergegeven.




Figure 2: UMAP-visualisatie van cellen. Elke stip representeert een cel.




Figure 3: UMAP: Het gen *Tenm3*-intron wordt weergegeven in de mate dat het voorkomt in de clusters.

Gropeer cellen in clusters

Cellen worden gegroepeerd met behulp van een community detection algoritme. In Figuur 4 is de clustering van cellen weergegeven in de UMAP-ruimte. Elke kleur en elk nummer vertegenwoordigt een cluster van cellen met vergelijkbare genexpressie.

Deze clusters vormen de basis voor verdere analyse, zoals het identificeren van celtypen en ontwikkelingsroutes.




Figure 4: UMAP: Clustering van cellen. Elke kleur en elk nummer representeert een cluster met vergelijkbare genexpressie.

Zoek markergenen die door elk cluster tot expressie worden gebracht

Om de clusters biologisch te interpreteren, wordt gekeken naar genen die specifiek tot expressie komen in elk cluster. In Figuur 5 is een dotplot weergegeven waarin per cluster de belangrijkste genen worden getoond.

Op de x-as staan de clusters en op de y-as de genen. De grootte van de stip geeft aan welk percentage cellen binnen een cluster het gen tot expressie brengt, terwijl de kleur de sterkte van expressie weergeeft.

Deze markergenen kunnen gebruikt worden om clusters te koppelen aan specifieke celtypen.

Voorzie de cellen van een annotatie op basis van het type

Op basis van de geïdentificeerde markergenen kunnen clusters worden gekoppeld aan bekende celtypen. In Figuur 6 zijn de clusters voorzien van biologisch geïnterpreteerde namen, zoals Epiblast, Visceral endoderm,




Figure 5: Dotplot: Expressie van markergenen per cluster. Grootte = percentage cellen, kleur = expressieniveau.

Differentiating cells en Mesoderm-like cells.

Deze annotatie maakt het mogelijk om de biologische betekenis van de clusters beter te begrijpen.




Figure 6: UMAP: Annotatie van clusters met celtypen. Kleuren representeren verschillende celtypen.

Trajectanalyse

Na clustering en annotatie kan de onderliggende relatie tussen cellen verder worden onderzocht met trajectanalyse. Hierbij wordt een continu ontwikkelingspad gereconstrueerd op basis van veranderingen in genexpressie.

In Figuur 7 is de geleerde trajectgrafiek weergegeven. De lijnen verbinden cellen langs mogelijke ontwikkelingsroutes. Vertakkingen in het traject wijzen op differentiatieprocessen waarbij cellen zich ontwikkelen naar verschillende celtypen.

Om de volgorde van cellen langs het traject te bepalen, worden cellen geordend in pseudotijd. Hierbij wordt een beginpunt gekozen op basis van biologisch vroege cellen (Epiblast).

In Figuur 8 is de pseudotijd weergegeven als een kleurgradiënt. Cellen met lage pseudotijd bevinden zich aan het begin van het traject, terwijl cellen met hogere pseudotijd verder gedifferentieerd zijn. Dit laat zien dat de gereconstrueerde trajecten overeenkomen met een biologisch ontwikkelingsproces.

In Figuur 9 is de verdeling van pseudotijd per celtype weergegeven. Hieruit blijkt dat Epiblast-cellen een lage pseudotijd hebben, terwijl meer gedifferentieerde celtypen hogere pseudotijdwaarden vertonen. Dit ondersteunt de gekozen richting van het traject.




Figure 7: UMAP met trajectgrafiek. Lijnen geven mogelijke ontwikkelingsroutes tussen cellen weer.




Figure 8: Pseudotijdvisualisatie. Kleur geeft de geschatte ontwikkelingsvolgorde van cellen weer.




Figure 9: Boxplot van pseudotijd per celtype.

Conclusie

In deze analyse is single-cell RNA-seq data van het tijdstip E6.5 succesvol ingelezen en verwerkt met behulp van het Monocle3 pakket. Door middel van preprocessing en dimensionale reductie konden cellen worden gevisualiseerd in een UMAP-representatie, waarin duidelijke clusters zichtbaar waren (Figuur 2).

De clustering van cellen maakte het mogelijk om groepen met vergelijkbare genexpressie te identificeren (Figuur 4). Vervolgens zijn marker genen bepaald per cluster (Figuur 5), wat de biologische interpretatie van deze clusters ondersteunde. Op basis hiervan konden de clusters worden geannoteerd naar bekende celtypen, zoals Epiblast, Visceral endoderm, Differentiating cells en Mesoderm-like cells (Figuur 6).

Met behulp van trajectanalyse werd de onderliggende relatie tussen cellen verder onderzocht. De gereconstrueerde trajectgrafiek (Figuur 7) liet zien hoe cellen met elkaar verbonden zijn binnen een continu ontwikkelingsproces, waarbij vertakkingen wijzen op mogelijke differentiatiepaden. De pseudotijdanalyse (Figuur 8) bevestigde deze structuur en liet een duidelijke overgang zien van vroege naar meer gedifferentieerde celtypen. Dit werd verder ondersteund door de verdeling van pseudotijd per celtype (Figuur 9).

Hieruit kan worden geconcludeerd dat de data van tijdstip E6.5 geschikt is gemaakt voor analyse in Monocle3 en dat de combinatie van clustering en trajectanalyse waardevolle inzichten geeft in de dynamiek van celontwikkeling. De resultaten tonen aan dat celontwikkeling een continu proces is, waarin cellen geleidelijk veranderen en differentiëren naar verschillende celtypen.