

08_e8.5_data_laden

2025-11-27

Deelvraag: Hoe ziet de single-cell RNA-seq dataset van muizenembryo's op ontwikkelingsstadium E8.5 eruit en welke cellulaire clusters kunnen op basis van genexpressie worden onderscheiden?

Methode

Voor deze analyse is er gebruikgemaakt van single-cell RNA-seq data afkomstig van muizenembryo's op ontwikkelingsstadium E8.5. De data bestaat uit een genexpressiematrix waarin per cel het aantal RNA-moleculen per gen is vastgelegd, aangevuld met metadata over cellen en genen.

Om de kwaliteit van de data te beoordelen, zijn verschillende kwaliteitskenmerken per cel geanalyseerd: het aantal gedetecteerde genen, het totaal aantal RNA-moleculen en het percentage mitochondriaal RNA. Cellen met een extreem laag of hoog aantal genen, of met een verhoogd mitochondriaal RNA-percentage, zijn verwijderd om technische ruis en beschadigde cellen uit te sluiten.

Na kwaliteitscontrole is de data genormaliseerd zodat expressiewaarden tussen cellen onderling vergelijkbaar zijn. Vervolgens zijn de meest variabele genen geselecteerd voor verdere analyse, omdat deze genen het meest informatief zijn voor het onderscheiden van celtypen en toestanden.

Resultaten

De kwaliteitscontrole laat zien dat het merendeel van de cellen binnen de verwachte biologische variatie valt wat betreft genexpressie en mitochondriaal RNA. Enkele cellen vertonen echter afwijkende waarden, wat kan wijzen op technische afwijkingen of lage celkwaliteit. Deze cellen zijn daarom uitgesloten van verdere analyse.

Normaliseren van de gegevens

De data wordt genormaliseerd door de totale expressie van elke cel om te zetten naar 10.000 en vervolgens een log-transformatie te nemen (het getal weer kleiner maken). Hierdoor kunnen de getallen per cel met elkaar vergeleken worden.

Kenmerkselectie

Om de belangrijkste biologische variatie in de data te identificeren, zijn de 2000 meest variabele genen geselecteerd. Deze genen dragen het sterkst bij aan verschillen tussen cellen en vormen de basis voor de daaropvolgende dimensionale reductie.




Figure 1: Kwaliteitscontrole van E8.5 single-cell data: Violinplots van (links) het aantal gedetecteerde genen per cel, (midden) het totaal aantal RNA-moleculen per cel en (rechts) het percentage mitochondriaal RNA. Elke stip representeert een individuele cel.




Figure 2: Relatie tussen kwaliteitskenmerken per cel: Scatterplots waarin links het percentage mitochondriaal RNA is uitgezet tegen het totaal aantal RNA-moleculen per cel, en rechts het aantal gedetecteerde genen tegen het totaal aantal RNA-moleculen. Elke stip representeert één cel.




Figure 3: Selectie van variabele genen: De gemiddelde genexpressie is uitgezet tegen de gestandaardiseerde variantie. De 2000 meest variabele genen zijn rood weergegeven; de tien genen met de hoogste variatie zijn gelabeld.

De gegevens schalen

De gemiddelde expressie over de cellen wordt op 0 gesteld, ook wordt de variantie over de cellen op 1 gesteld.

Lineaire dimensionale reductie uitvoeren

Met behulp van principal component analysis (PCA) is de hoge-dimensionale genexpressiedata samengevat in een kleiner aantal hoofdcomponenten, waarbij elke component een deel van de totale variatie in de data beschrijft.




Figure 4: Genbijdragen aan de eerste principal component (PC1): Visualisatie van de genen die het sterkst bijdragen aan PC1.

Dimensionaliteit

Om ruis te voorkomen in verdere analyse wordt er gekeken hoeveel PC's meegenomen moeten worden. Hiervoor kan er gebruik gemaakt worden van een elbowplot. In deze plot worden de PC's op de x-as geplaatst en de standaard deviatie op de y-as. Er ontstaat een soort van arm, waarbij de elleboog het keerpunt is. De PC's voor de elleboog worden meegenomen en de PC's na de elleboog worden niet meegenomen. Het verschil tussen de PC's na de elleboog is niet relevant genoeg om mee te nemen. In figuur 7 is de elleboog zichtbaar tussen 9 en 10.




Figure 5: PCA-plot van cellen: Projectie van cellen op de eerste twee principal components, waarbij elke stip een individuele cel representeert.




Figure 6: Heatmap van genexpressie geassocieerd met PC1: Heatmap van genen die bijdragen aan PC1, waarbij rijen genen en kolommen cellen representeren. Paars is een lage PCA-score, geel is een hoge PCA-score. Clusters worden hiermee gevisualiseerd




Figure 7: Elbowplot voor bepaling van het aantal principal components: De standaarddeviatie van opeenvolgende principal components, waarbij het knippunt rond PC9–PC10 aangeeft welke componenten informatief zijn voor verdere analyse.

Clusteren

Nadat de juiste PC's zijn gekozen (1-10), verdeelt Seurat de cellen in groepen (clusters). Het programma kijkt hiervoor welke cellen het meest op elkaar lijken en verbindt die in een netwerk. Vervolgens zoekt het naar dicht bij elkaar liggende groepjes cellen binnen dat netwerk. Met de resolutie-instelling kun je bepalen of je grotere, bredere groepen of juist kleinere, gedetailleerdere groepen krijgt. In dit geval is er gekozen voor een resolutie van 0.5.

Niet-lineaire dimensionale reductie uitvoeren (UMAP/tSNE)

Op basis van de eerste tien principal components zijn cellen geclusterd om groepen met vergelijkbare gen-expressiepatronen te identificeren. Deze clusters zijn vervolgens gevisualiseerd met behulp van UMAP, een niet-lineaire dimensionale reductiemethode.




Figure 8: UMAP-visualisatie van E8.5 cellen: Projectie van cellen in een tweedimensionale ruimte, waarbij kleuren de verschillende clusters weergeven. Elke stip representeert één cel.

Het vinden van differentieel tot expressie gebrachte kenmerken (clusterbiomarkers)

Om de biologische betekenis van de clusters te onderzoeken, zijn genen geïdentificeerd die specifiek tot expressie komen in individuele clusters. Deze marker genen geven inzicht in mogelijke celtypen of ontwikkelingsstadia.




Figure 9: Expressie van Tenm3-intron per cluster: Violinplot waarin de expressieniveaus van het gen Tenm3-intron per cluster worden weergegeven.




Figure 10: Ruimtelijke expressie van Ptn-intron: UMAP-plot waarin de expressie van Tenm3-intron per cel is weergegeven, waarbij hogere expressie wordt aangegeven door een intensere kleur.




Figure 11: Heatmap van cluster-specifieke markergenen: Heatmap van de tien meest differentieel tot expressie gebrachte genen per cluster, waarbij geel een hoge en paars een lage expressie aanduidt.


```
## # A tibble: 180 x 7
## # Groups:   cluster [18]
##       p_val avg_log2FC pct.1 pct.2 p_val_adj cluster gene
##       <dbl>      <dbl> <dbl> <dbl>      <dbl> <fct>   <chr>
## 1 8.14e- 27      6.18 0.022 0.001 3.67e- 22 0      Wnt8b-exon
## 2 1.24e- 22      5.98 0.018 0      5.57e- 18 0      Kcna1-exon
## 3 5.47e-274      5.37 0.262 0.015 2.46e-269 0      Pax5-intron
## 4 3.83e- 30      5.31 0.023 0      1.73e- 25 0      Pdzhph1-exon
## 5 3.73e- 14      5.30 0.011 0      1.68e-  9 0      Egr2-intron
## 6 5.33e-162      5.23 0.142 0.005 2.40e-157 0      Pax5-exon
## 7 5.50e- 28      5.22 0.022 0      2.48e- 23 0      En1-intron
## 8 1.50e- 17      5.14 0.017 0.001 6.75e- 13 0      Prdm13-exon
## 9 1.98e- 20      5.07 0.017 0.001 8.89e- 16 0      Garem2-intron
## 10 3.25e-278      5.03 0.238 0.009 1.46e-273 0      Miat-exon
## # i 170 more rows
```




Figure 12: UMAP-visualisatie van E8.5 cellen: Projectie van cellen in een tweedimensionale ruimte, waarbij kleuren de verschillende clusters weergeven. Elke stip representeert één cel. De namen van de clusters zijn weergegeven.

Conclusie

De single-cell RNA-seq data van muizenembryo's op tijdstip E8.5 vertoont duidelijke variatie, wat wijst op de aanwezigheid van meerdere celpopulaties. Na kwaliteitscontrole en normalisatie konden verschillende

clusters worden onderscheiden op basis van genexpressiepatronen.

De clustering en markeranalyse suggereren dat deze clusters biologische verschillen weerspiegelen, mogelijk gerelateerd aan verschillende celtypen of ontwikkelingsstadia binnen het embryo. Deze resultaten vormen een basis voor verdere interpretatie en vergelijking met andere tijdstippen in de embryonale ontwikkeling.